Codename: Capybara

Auto-Alignment for Music and Lyrics



SCPARK

소개



비와코 호수가 내려다보이는 :)

- 박수철
- 생성모델 알고리즘 연구랩 logp(x) 운영
  @ 모두의연구소
- 음원분리 서비스 GSEP,
  가사매칭 서비스 GTS 개발
  @ GAUDIOLAB
- Adaptive TTS 서비스 VSpeech 개발
  @ VIVESTUDIOS
- 셀럽 TTS 서비스 개발
  @ SM Entertainement
- Android 어플리케이션, 오디오 출력 모듈 개발
- 서울대 작곡/컴퓨터공학 전공

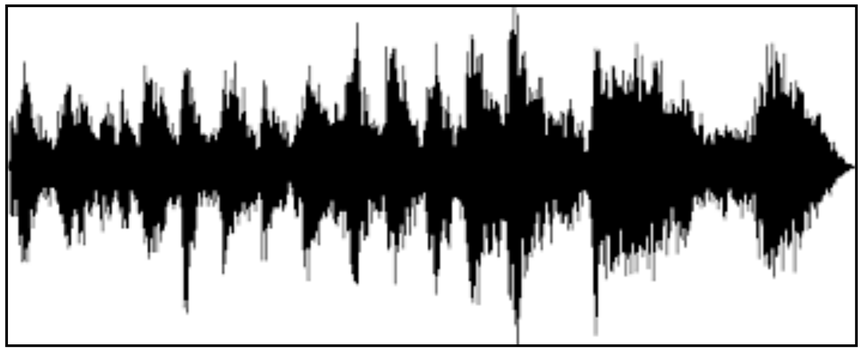
목차

- Introduction to Alignment for Music
- Background: Alignment for Speech
- Problems in Alignment for Music
  - Too long
  - Non-monotonic
- Solution: Capybara1
  - Dataset
  - Model
  - Results
- Remaining Problems
  - Accuracy
  - Line End Time
- Solution: Capybara2
  - Dataset using Singing-TTS
  - Model
  - Results



Introduction to Alignment for Music

- Alignment for Music : 노래와 가사가 주어졌을 때, 서로 어디에 매칭되는지 찾는 일



Music

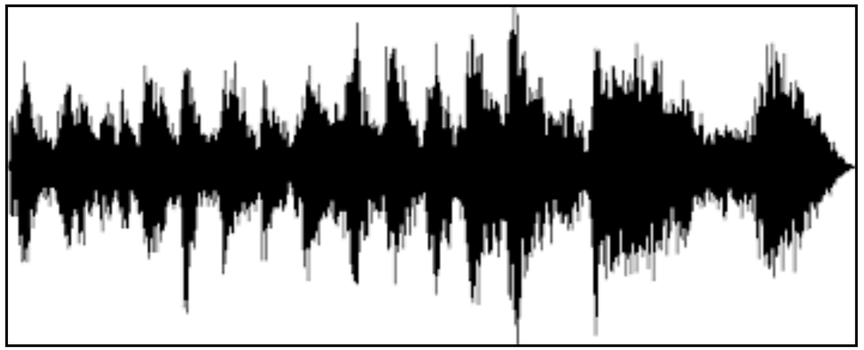
달이 익어가니 서둘러 젊은 피야
민들레 한 송이 들고
사랑이 어지러이 떠다니는 밤이야
날아가 사뿐히 이루렴

Lyrics



Introduction to Alignment for Music

- 스트리밍 서비스를 위한 line alignment와 노래방을 위한 character alignment로 나뉨



Music

달이 익어가니 서둘러 젊은 피야
민들레 한 송이 들고
사랑이 어지러이 떠다니는 밤이야
날아가 사뿐히 이루렴

Lyrics

달이 익어가니 서둘러 젊은 피야	**0.00**
민들레 한 송이 들고	**5.21**
사랑이 어지러이 떠다니는 밤이야	**11.06**
날아가 사뿐히 이루렴	**16.44**

Line Alignment

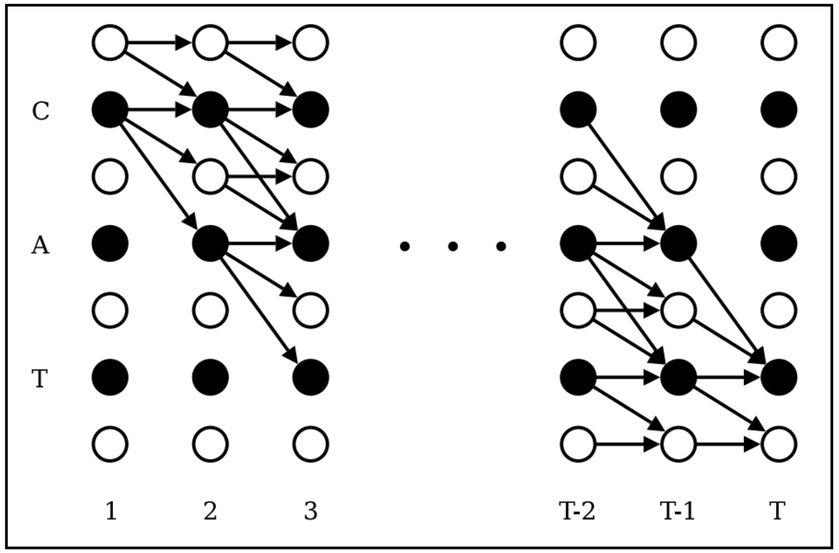
ㄷ: **0.00**, ㅏ: **0.23**, ㄹ: **0.76**, ㅇ:**1.26**, ㅣ:**1.77**, …

Character Alignment

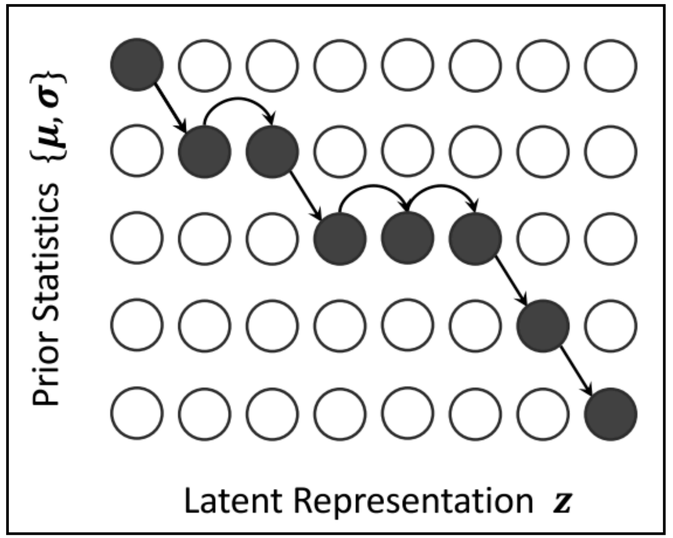
Background: Alignment for Speech

- Speech recognition을 위한 CTC alignment [1]
  Speech Synthesis를 위한 MAS alignment [2] 등이 이미 존재

- Speech와 text가 있을 때, unsupervised 방법으로 alignment를 구하는 알고리즘



CTC alignment의 예 [1]

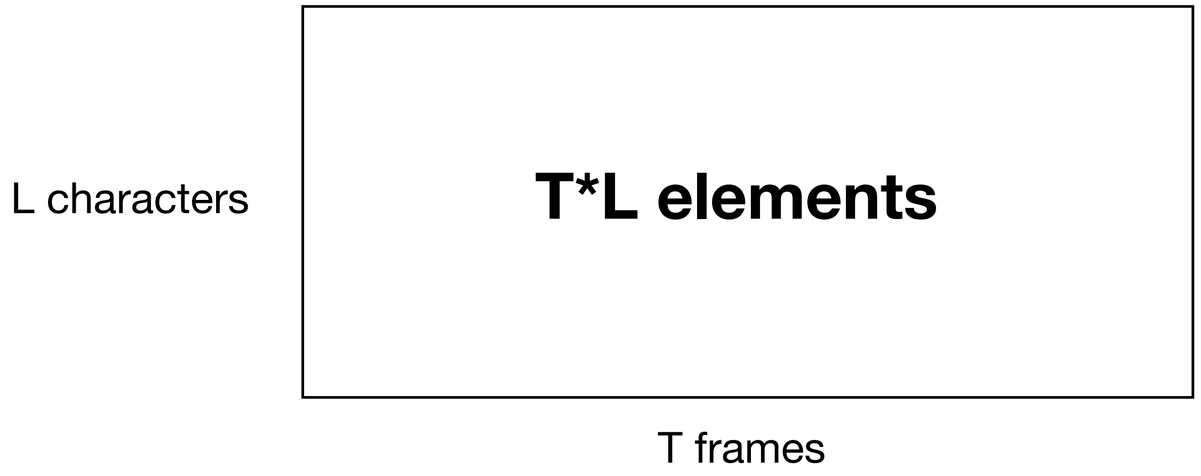


MAS alignment의 예 [2]

[1] Graves, Alex, et al. "Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks."
[2] Kim, Jaehyeon, et al. "Glow-tts: A generative flow for text-to-speech via monotonic alignment search."

Problems in Alignment for Music - Too Long

- Music and Lyrics 데이터의 경우 CTC나 MAS를 적용하기에 너무 김
- T=10K frames (약 5분), L=1K개 characters의 경우, alignment를 구하는데 T*L=10M elements를 가진 matrix가 필요



- T*L에 비례하는 공간을 탐색하여 alignment를 구하는데 시간이 오래걸림

Problems in Alignment for Music - Non-monotonic

- Speech와 달리 music은 메인 선율과 코러스 등으로 인해 monotonic 하지 않음
- CTC와 MAS는 monotonic한 alignment를 찾는 알고리즘임

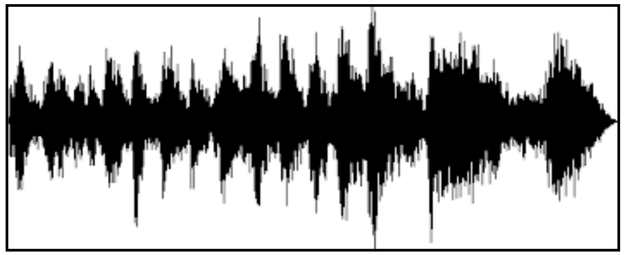
Solution: Capybara1 - Dataset

- 스트리밍 업체 B사에서 music, lyrics, line start time 정보가 있는 70K개 정도의 데이터셋을 제공 받음

Lyrics	Time
Prelude...	1.9
Show me the way to your heart	6.2
I am searching	10.9
But I’m drifting apart	14.2
Everything's gone, far away	18.5
Here we’re standing now	23.9
With no words left to say	28.1
Gave you power	32.4
Fell on the floor	34.9
Silence, never thought you hurt so bad	37.6
In darkest hours	44.8
Slept at your door	48.0
Wishing all would be just like before	51.5
Let me find my piece of heaven	57.3
Let me find my way back home	63.6
I want this love to last forever	69.8
And back together, rise once again	76.5
From the ashes to the sky...	82.8
Has someone taken my place?	97.1
Am I falling?	102.3

Solution: Capybara1 - Overall Model

- Line alignment, Character alignment model로 나눔
- Line alignment model는 music 전체와 lyrics 전체를 입력 받아서 line별 start time을 출력
- Chracter alignment model은 line별로 입력 받아서 character별 start time을 출력



Music

달이 익어가니 서둘러 젊은 피야
민들레 한 송이 들고
사랑이 어지러이 떠다니는 밤이야
날아가 사뿐히 이루렴

Lyrics

달이 익어가니 서둘러 젊은 피야	**0.00**
민들레 한 송이 들고	**5.21**
사랑이 어지러이 떠다니는 밤이야	**11.06**
날아가 사뿐히 이루렴	**16.44**

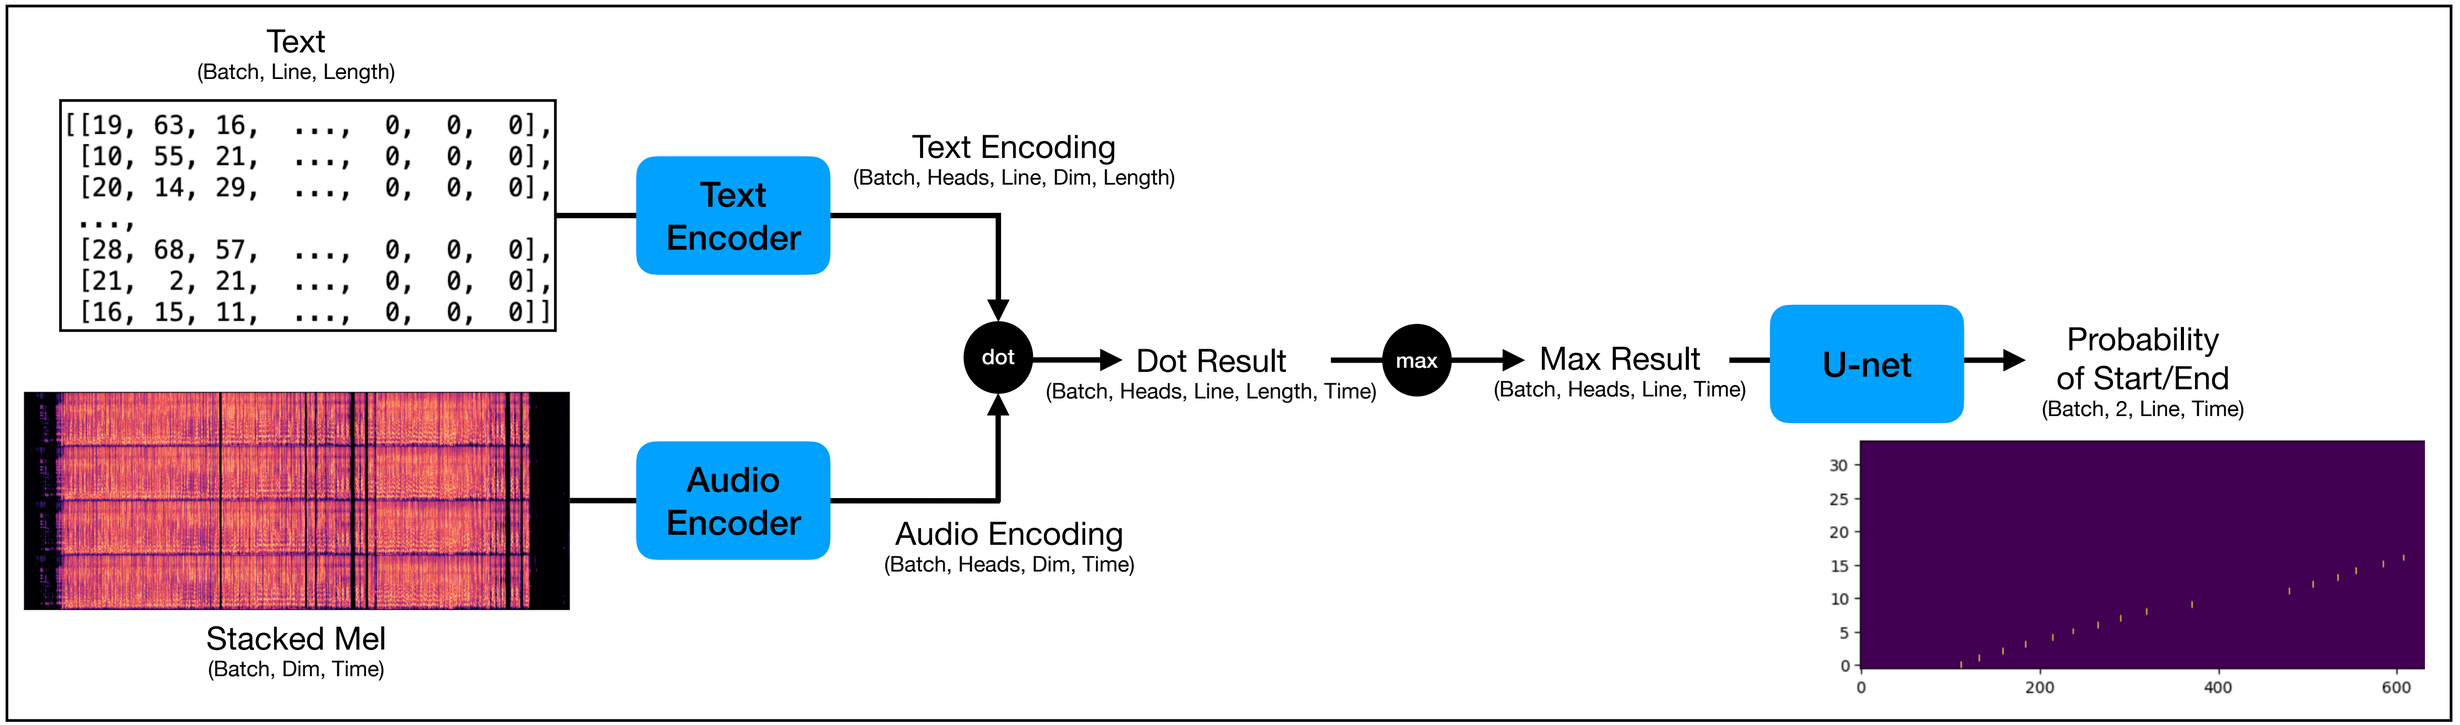
Line Alignment

ㄷ: **0.00**, ㅏ: **0.23**, ㄹ: **0.76**, ㅇ:**1.26**, ㅣ:**1.77**, …

Character Alignment

Solution: Capybara1 - Line Alignment Model

- Music, lyrics를 입력받아서 line start time정보를 출력하는 모델을 설계
- Music을 mel-spectrogram으로 변환, audio encoder로 인코딩
- Lyrics를 IPA로 변환, text encoder로 인코딩
- Dot-product 적용하여 correlation을 측정하고 length축으로 max pooling하여 line별 최대 correlation 구함
- U-net을 통해 최종 line start time을 표시하는 alignment를 출력

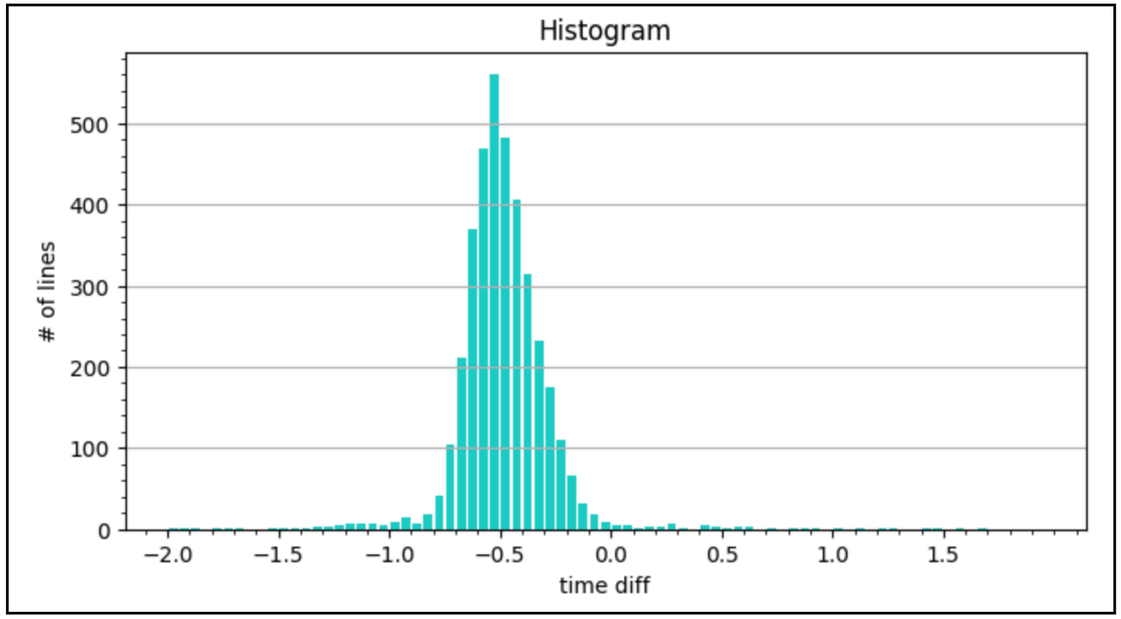


Capybara1 Line Alignment Model

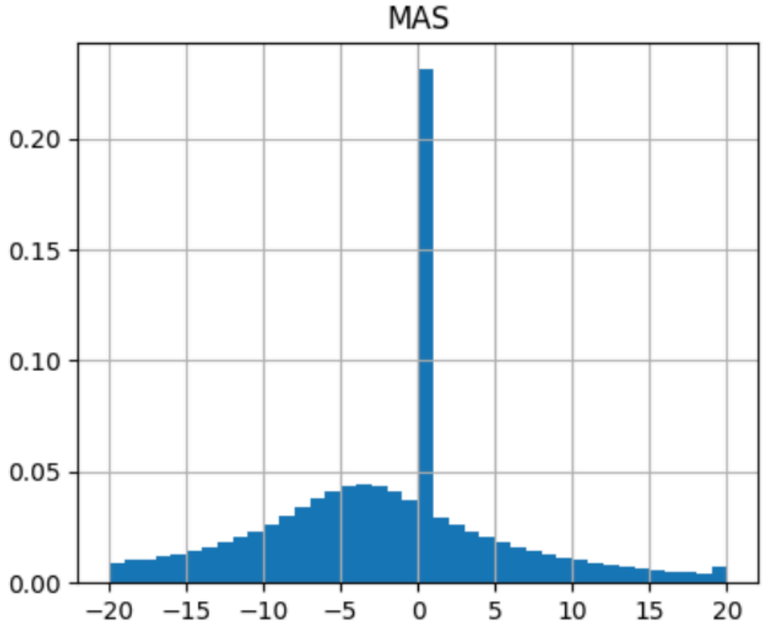
Remaining Problems - Accuracy

- Line alignment
  Dataset이 사람이 직접 찍은 데이터이므로 다소 부정확

- Character alignment
  MAS로 구한 alignment는 unsupervised 방법이며 상당히 부정확



Line alignment 결과
MAD = 0.210s

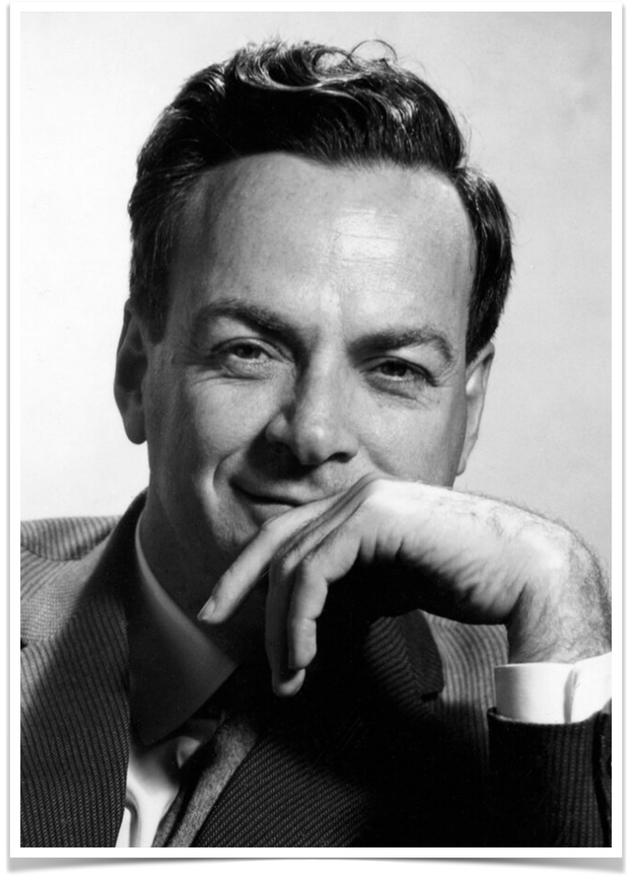


Character alignment 결과
100ms이내 46%, 200ms 이내 68%

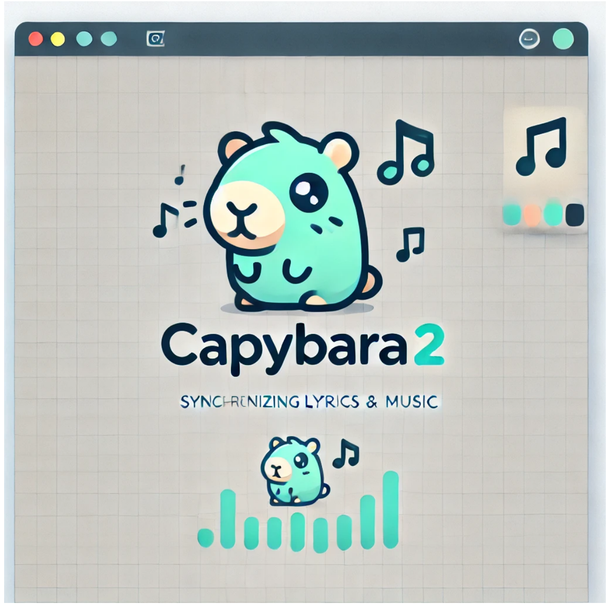
Remaining Problems - Line End Time

- 가지고 있는 dataset은 스트리밍 서비스용 데이터라 line별 start time만 존재
  - 스트리밍 서비스용으로는 무리 없음

- Line별 end time을 구할 필요성
  - Character alignment에 넣을 line구간을 정확하게 하기 위함



What I cannot create, I do not understand.
- Richard P. Feynman



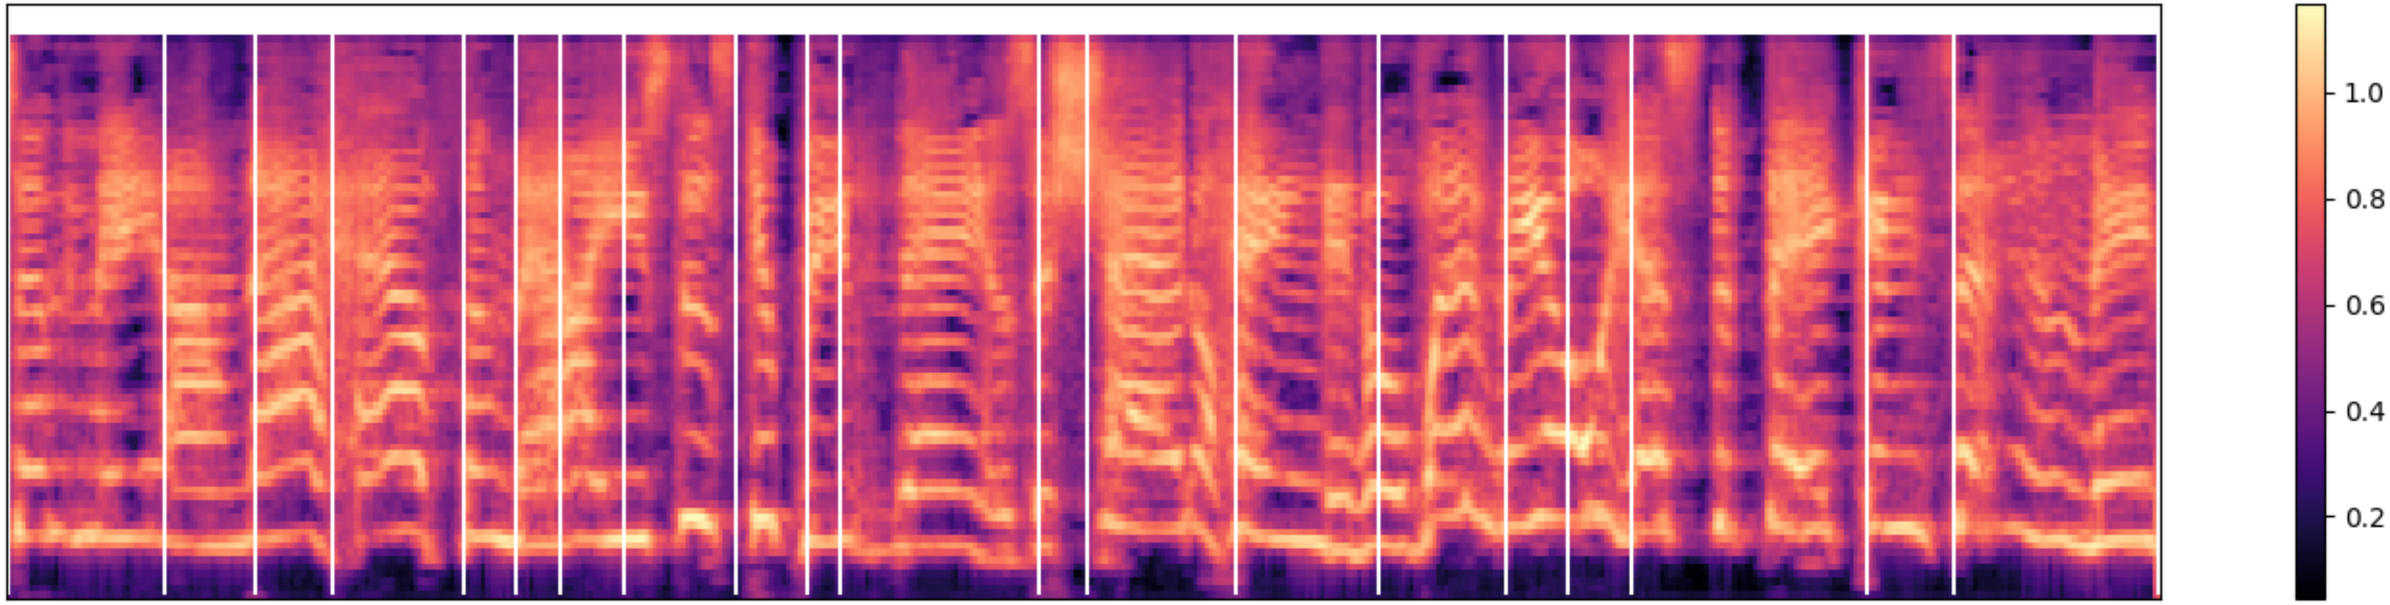
Music을 만들 수 없으면, alignment를 구할 수 없다.
- Capybara2

Solution: Capybara2 - Dataset using Singing-TTS

- Singing TTS를 이용하여 가사가 주어졌을 때, 랜덤 duration과 랜덤 음높이, 랜덤 speaker로 music을 만듬

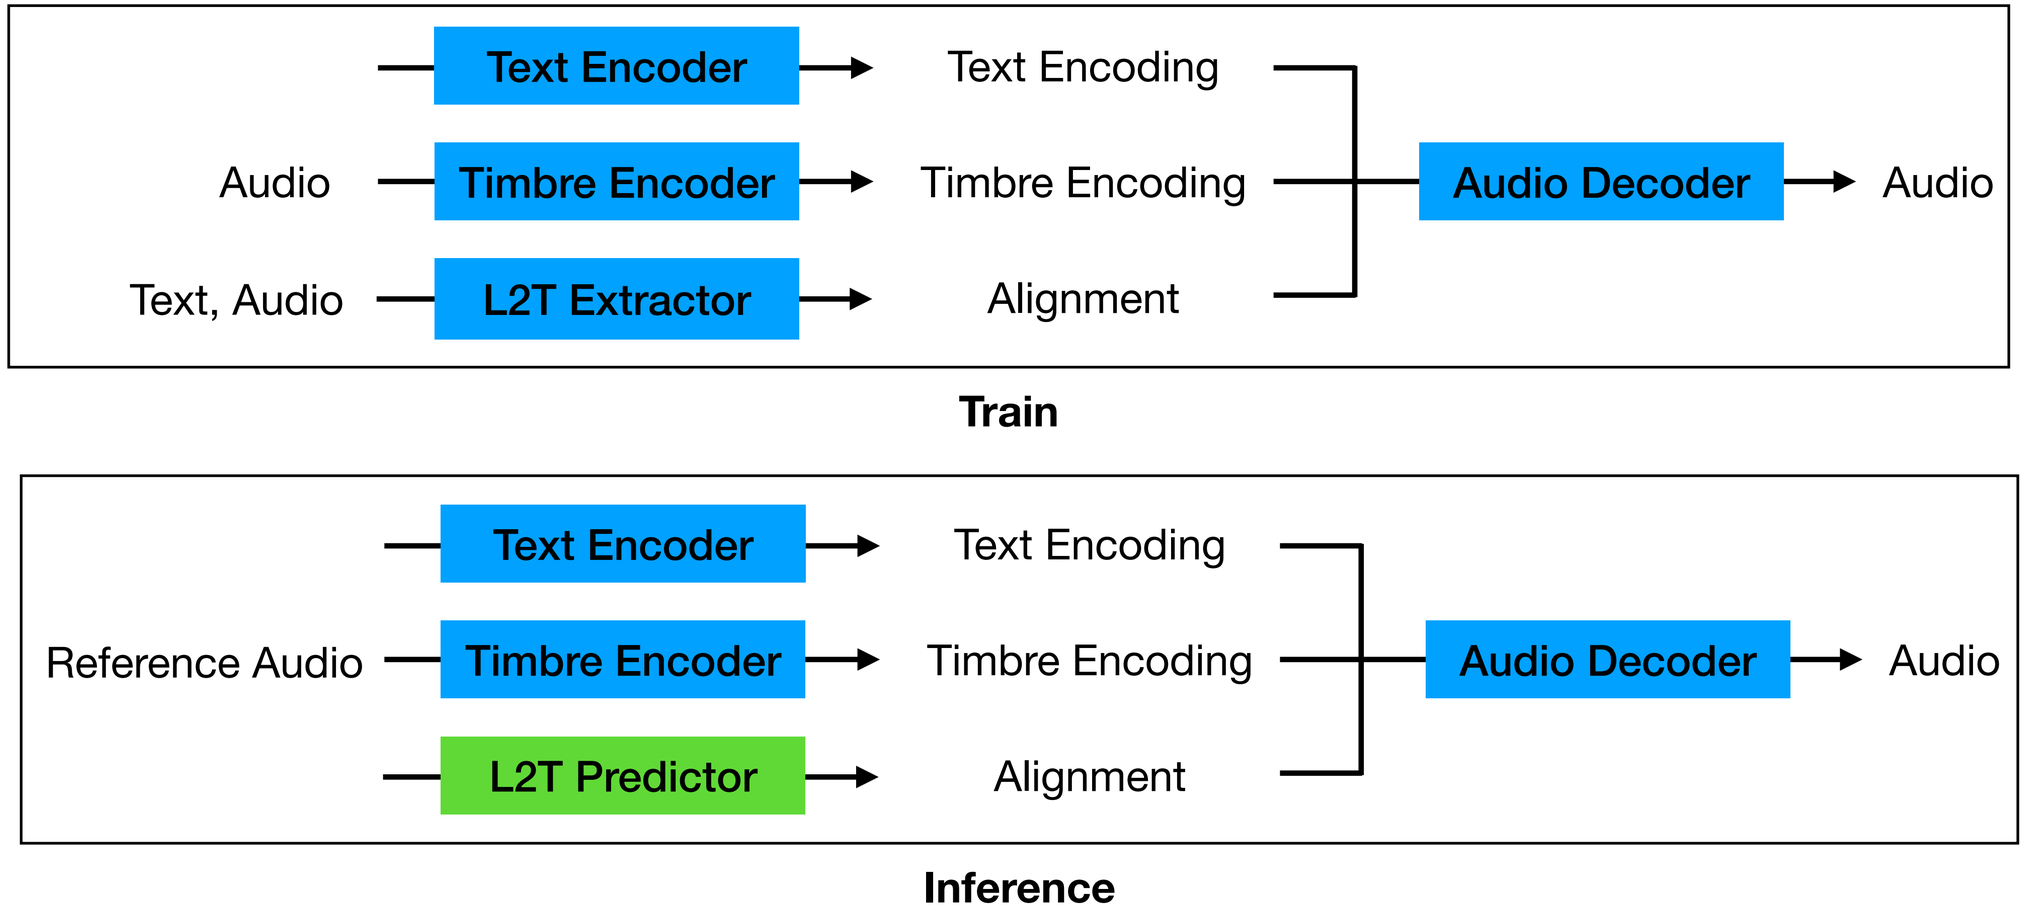
- music과 character별 정확한 time 정보를 가진 dataset 확보

"Suddenly I'm not half the man I used to be There's a shadow hanging over me Oh, yesterday came suddenly."



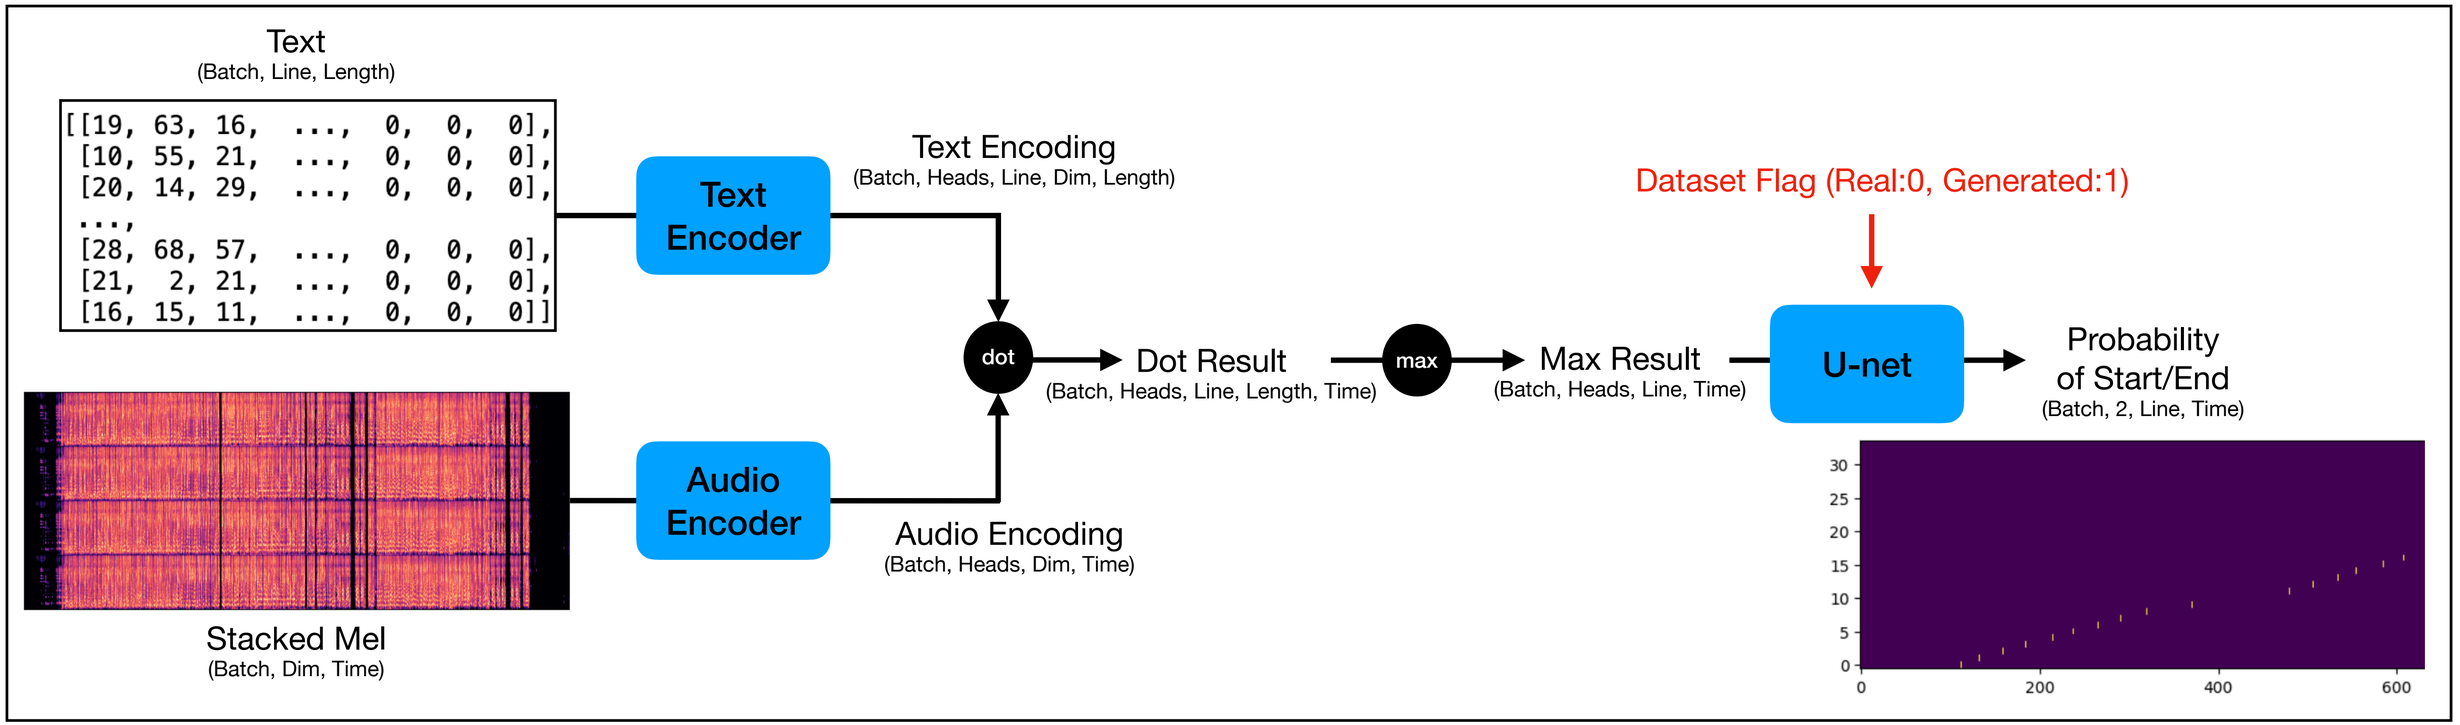
Solution: Capybara2 - Singing-TTS

- Singing-TTS 구성
  Text Encoder : CBHG, Timbre Encoder : ECAPA-TDNN
  L2T Extractor : MAS, Audio Decoder : 2D Unet, Flow-Matching



Solution: Capybara2 - Line Alignment Model

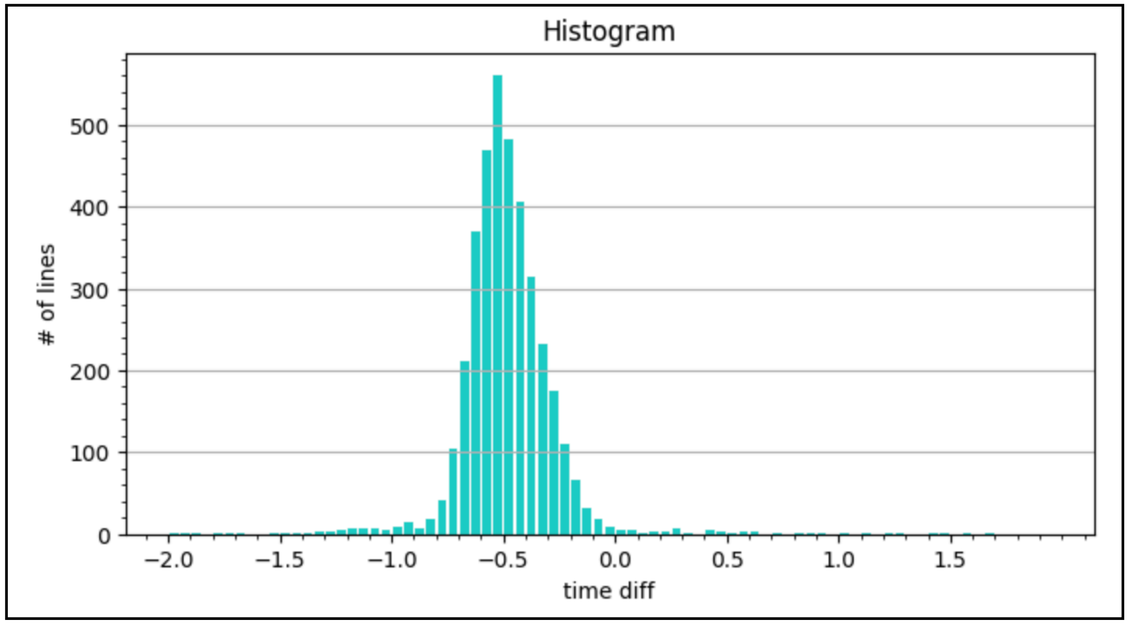
- Real dataset, generated dataset을 함께 트레이닝
- Real dataset은 다소 부정확한 정답을 가졌으나 다양함
- Generated dataset은 정확한 정답을 가졌으나 다양성이 부족
- U-net 부분에 real과 generated에 따라 다른 flag를 적용하여 작동 분리



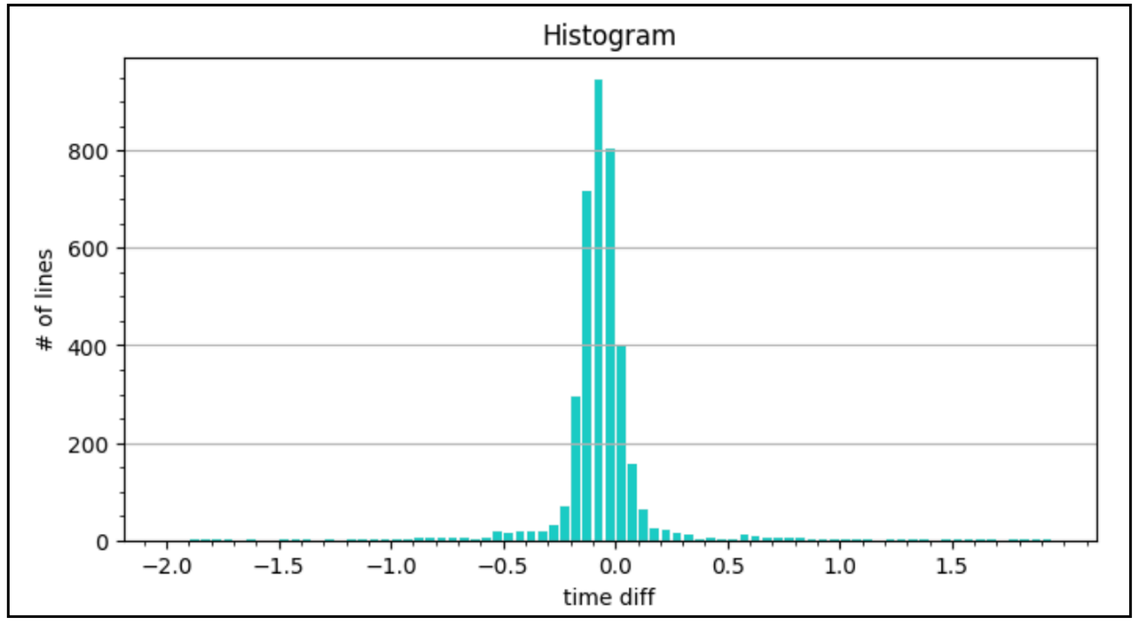
Capybara2 Line Alignment Model

Solution: Capybara2 - Results

- Capybara1 대비 line accuracy 상승 (MAD=0.21s -> 0.15s)
- End-time와 비교적 정확한 character start time 확보



Capybara1 Line Alignment Results, MAD=0.21s



Capybara2 Line Alignment Results, MAD=0.15s

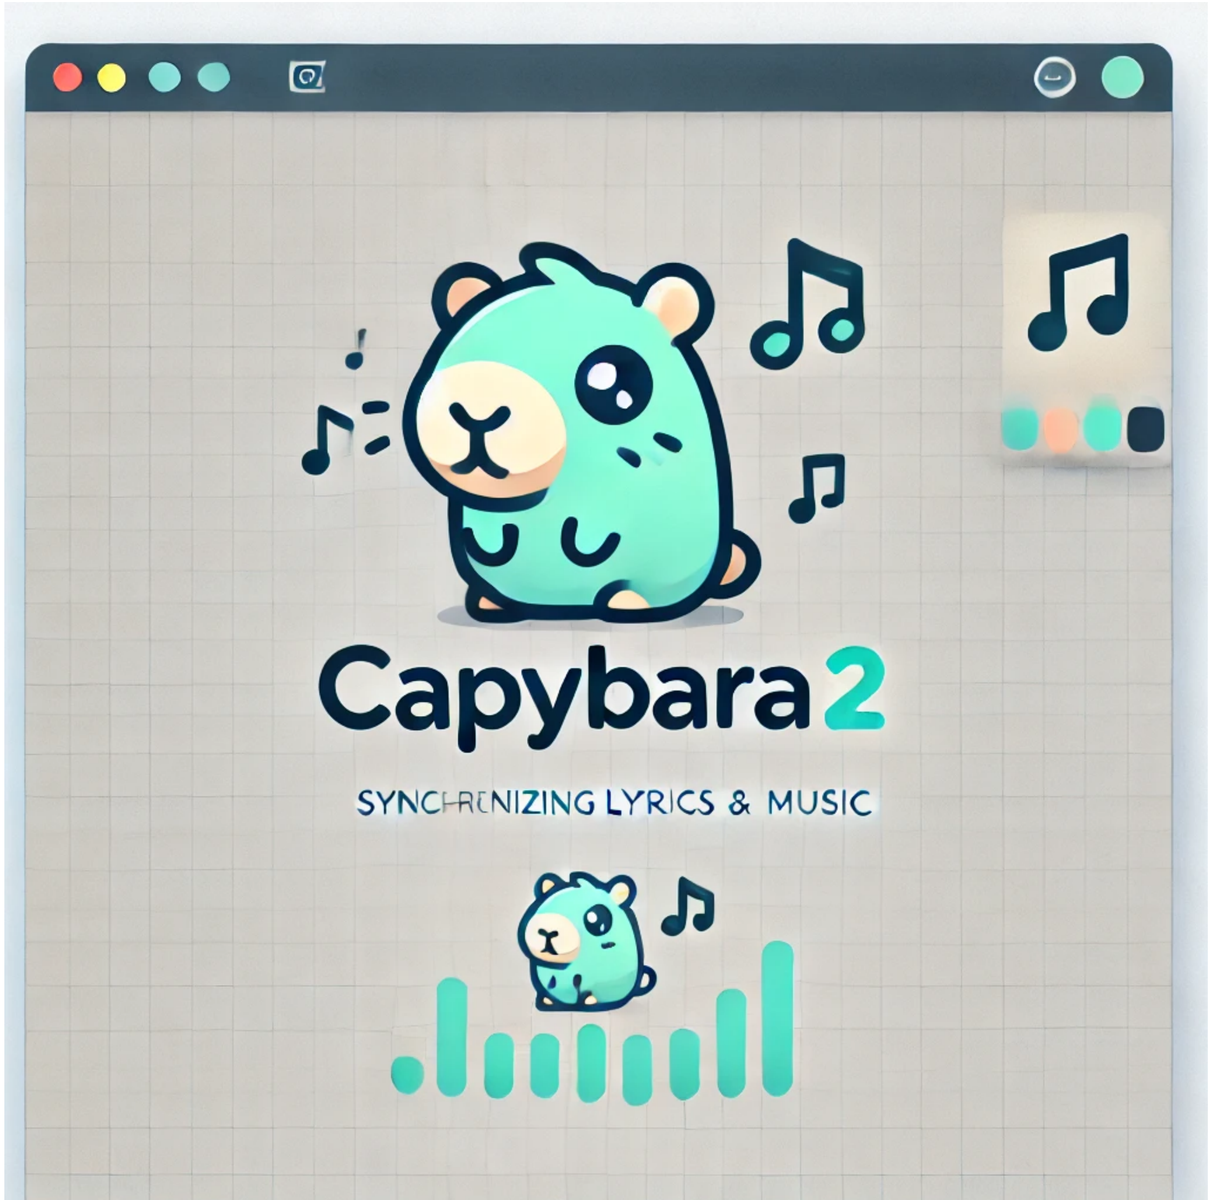
Conclusion

- 스트리밍, 노래방 서비스를 위해 가사와 노래를 매칭하기 위한 딥러닝 모델 필요

- 기존의 ASR, TTS를 위한 alignment 알고리즘은 사용하기에 어려움이 있음
  - 노래는 길이가 너무 길다는 문제
  - 노래는 monotonic하지 않다는 문제

- Capybara1
  - 가사와 노래를 dot-product attention하고, U-net을 사용하여 alignment를 출력
  - 수작업으로 만들어 놓은 다소 부정확한 데이터를 사용

- Capybara2
  - 가사와 노래 reference가 주어졌을 때 가사에 맞는 노래를 출력하는 Singing-TTS를 개발
  - Singing-TTS에 의해 정확한 alignment를 구함
  - 수작업으로 만든 데이터셋과 Singing-TTS에서 만든 데이터셋을 함께 트레이닝하여 성능 개선



감사합니다